Studio IA Local · Manual de la app Android

La app **Studio IA** tiene dos modos, que eliges al abrirla y puedes cambiar cuando quieras:

	📱 **Autónomo**	🖥️ **Conectado al PC**
Dónde se ejecuta la IA	En el propio móvil	En tu PC, por la Wi-Fi de casa
Necesita PC	No	Sí, con Studio IA Local abierto
Necesita Internet	Solo para descargar los modelos una vez	No
Modelos	Pequeños (1,7B a 4B)	Los que aguante tu PC (8B, 14B…)
Velocidad y calidad	Buena en móviles recientes	La mejor
Extras	Voz nativa de Android	Ejecución de Python, PDF/Word, generación de imágenes

En ambos modos tus datos se quedan en tus dispositivos.

1. Requisitos

- Android 8.0 o superior, de 64 bits (arm64).
- **Modo autónomo:** 6 GB de RAM como mínimo (8 GB o más recomendado), procesador de 2018 en adelante y entre 2 y 5 GB libres para los modelos.
- **Modo conectado:** el PC con Studio IA Local encendido, con `LAN=true` en `studio.env` (ver *Manual de Windows*, apartado 5), y móvil y PC en la misma Wi-Fi.

2. Instalar la app

Hay dos APK; instala **solo una**: - `StudioIA-Android-Snapdragon.apk` si tu móvil tiene procesador **Qualcomm Snapdragon**: añade Qualcomm Genie, que usa la **NPU Hexagon** y la GPU Adreno (unos 85 MB más). - `StudioIA-Android.apk` para el resto (MediaTek, Exynos, Tensor…).

Las dos se actualizan entre sí sin perder datos.

1. Copia la APK al móvil (cable USB, Google Drive, correo…) o descárgalo directamente en él.
2. Ábrelo desde la app *Archivos* o *Descargas*.
3. Android pedirá permiso para **instalar aplicaciones desconocidas** desde esa app: actívalo y vuelve atrás.
4. Pulsa **Instalar**. Si Play Protect avisa de que no conoce la app, pulsa **Instalar de todas formas**. Aparece porque la app no se distribuye por Google Play.

3. Modo autónomo (solo el móvil)

1. Abre la app y pulsa **Usar solo este móvil (autónomo)**.
2. Se abre la pestaña ⚙️ **Modelos** con los datos de tu teléfono y el perfil recomendado para su memoria:
   - **Gemma 3 4B** (3,4 GB): conversa y **ve imágenes**. Para móviles con 8 GB de RAM o más.
   - **Qwen3 4B** (2,5 GB): solo texto, el más fiable usando herramientas.
   - **Qwen3 1.7B** (1,1 GB): solo texto y rápido, para móviles con 6 GB.
3. Pulsa **Descargar los que faltan** (mejor con Wi-Fi) o toca otro perfil para cambiarlo. La descarga se puede reanudar si se corta.
4. Cuando el indicador diga **Listo · local**, ya puedes conversar, incluso en modo avión.

Qué incluye el modo autónomo: - **Equipo de agentes**: supervisor, investigador, analista, escritor y observador, editables en 🤖 Agentes. - **Memoria persistente**: recuerda hechos sobre ti entre conversaciones (🧠 Memoria). - **Workspace**: archivos de texto que tú y los agentes creáis, buscables por significado. Están en `Android/data/com.studioia.local/files/workspace`. - **Visión** con el perfil Gemma 3: adjunta o haz una foto con 📎. - **Voz**: 🎙️ usa el dictado de Android y 🔊 su síntesis de voz. Para que funcionen sin conexión, descarga el español en *Ajustes → Sistema → Idiomas → Reconocimiento de voz sin conexión*. - **Otros modelos**: pega la URL de cualquier archivo `.gguf` en «Descargar modelo». - **Otros motores (v1.3)**: además de llama.cpp, la app trae **ONNX Runtime GenAI** (CPU), **ExecuTorch** (CPU o GPU con Vulkan), **LiteRT-LM** de Google (CPU o GPU) y, en la APK Snapdragon, **Qualcomm Genie** (NPU, GPU o CPU). En ⚙️ Modelos → **Dónde se ejecuta cada modelo** eliges motor y ubicación (CPU, GPU o NPU) o lo dejas en automático; ⚡ **Medir** prueba todas las combinaciones y el automático se queda con la más rápida. Pulsa **Chat** en un modelo para usarlo. Para descargarlos, escribe el repositorio de Hugging Face (`org/repo`, o `org/repo/carpeta` para una subcarpeta). Se baja todo lo que contiene, así que elige uno con un solo modelo o la subcarpeta del que quieras. OpenVINO, MLC y TensorRT no existen para móviles y aparecen tachados. - En el móvil la **GPU y la NPU comparten la RAM** del teléfono: no hay VRAM aparte, así que elegir GPU o NPU cambia la velocidad y el consumo, no cuánto modelo cabe. La visión solo funciona con llama.cpp.

Consejos: - La primera respuesta tarda más porque el modelo se carga en memoria. Cierra otras apps para dejarle RAM. - Desde la versión 1.2 el motor usa la mitad de memoria para el contexto y reaprovecha lo ya procesado de la conversación, así que a partir del segundo mensaje empieza a responder antes. Las conversaciones muy largas se recortan a los últimos mensajes; para un tema nuevo, empieza una conversación nueva. - El botón ■ **Parar** corta una respuesta que se alarga. - Las respuestas largas calientan el teléfono y gastan batería; es normal. - Si Android cierra la app en segundo plano, el motor se detiene y vuelve a arrancar al abrirla. - Con modelos tan pequeños, pide las cosas de una en una y con instrucciones claras.

4. Conectar con el PC

1. En el PC, arranca StudioIA.exe con `LAN=true`. La ventana muestra: `Servidor: http://192.168.1.20:8765  Token: 7F3A9C21`
2. Abre **Studio IA** en el móvil.
3. Pulsa **Buscar el estudio en mi red** y elige tu PC de la lista, o escribe la dirección a mano (`192.168.1.20:8765`; el puerto se añade solo si lo omites).

4. Escribe el **token** y pulsa **Conectar**.

La app recuerda la conexión. Para cambiar de PC, pulsa el botón Atrás en la pantalla principal y elige **Cambiar de modo o servidor**.

5. Uso

La interfaz es la misma en los dos modos, adaptada a pantalla táctil: - ☰ (arriba a la izquierda): conversaciones. - ▤ (arriba a la derecha): workspace, memoria, agentes y modelos. - 📎: adjunta fotos de la galería, **haz una foto con la cámara** o adjunta documentos. - 🎙️: pulsa para grabar y otra vez para terminar. La grabación se transcribe en el PC. La primera vez Android te pedirá permiso para usar el micrófono; acéptalo y vuelve a pulsar. - 🔊: el móvil lee las respuestas en voz alta. - Los archivos del workspace se descargan en la carpeta *Descargas* del móvil.

Ejemplos: - Haz una foto a una factura y escribe: «Extrae los importes y guárdalos en facturas.csv». - Dicta: «Resume las notas de la reunión que subí ayer y dime las tareas pendientes». - Foto de una pizarra: «Pásalo a limpio en Markdown».

6. Botón Atrás

- Dentro de una página: vuelve atrás.
- En la pantalla principal: menú con **Cambiar de modo o servidor**, **Recargar** y **Salir**.

7. Problemas frecuentes

Síntoma	Solución
Autónomo: «El motor no arrancó»	Falta memoria: cierra apps o elige un perfil más pequeño. El mensaje de error aparece en ⚙️ Modelos.
Autónomo: la descarga falla	Comprueba la conexión y vuelve a pulsar; continúa donde se quedó.
Autónomo: «esta APK no incluye el motor»	La APK se compiló sin llama.cpp. Usa el modo conectado o una APK con motor.
«No se pudo conectar»	¿El PC está encendido y StudioIA.exe abierto? ¿Misma Wi-Fi? ¿`LAN=true`?
La búsqueda no encuentra el PC	Escribe la IP a mano. Algunas redes de invitados o routers con «aislamiento de clientes» impiden que los dispositivos se vean.
«Token de acceso incorrecto»	Copia el token que muestra la ventana del PC (también en `data\token.txt`).
El Firewall bloquea	En el PC: *Seguridad de Windows → Firewall → Permitir una aplicación →* marca StudioIA.exe y python.exe en «Privada».

Síntoma	Solución
El micrófono no graba	*Ajustes → Aplicaciones → Studio IA → Permisos → Micrófono → Permitir*.
La cámara no aparece al adjuntar	Concede el permiso de cámara a la app y vuelve a pulsar 📎.

8. Privacidad

La app no tiene publicidad ni analítica. En modo autónomo solo se conecta a Internet para descargar los modelos que tú pidas (desde huggingface.co); en modo conectado solo habla con la dirección de tu PC. La comunicación va por tu red local sin cifrar (HTTP), protegida por el token. No actives `LAN=true` en redes públicas (cafeterías, hoteles).

9. Alternativa sin app

Cualquier navegador del móvil puede abrir el estudio: escanea el código QR que muestra la ventana del PC. Algunos navegadores no permiten el micrófono en direcciones `http://` de la red local; la app sí lo permite.